



INSTITUTO INFNET

**LUCAS AMORIM BRUSCO
PEDRO CONCEIÇÃO COSTA
ANDRE LOUREIRO MONTINI FERREIRA
MARCELO DE AZEVEDO SAMPAIO
KAUAN LIMA OLIVEIRA**

**TRABALHO FINAL: MODELO DE REGRESSÃO LINEAR
Análise de Custo de Seguros/Planos de Saúde**

**RIO DE JANEIRO
2025**

LUCAS AMORIM BRUSCO
PEDRO CONCEIÇÃO COSTA
ANDRE LOUREIRO MONTINI FERREIRA
MARCELO DE AZEVEDO SAMPAIO
KAUAN LIMA OLIVEIRA

TRABALHO FINAL: MODELO DE REGRESSÃO LINEAR
Análise de Custo de Seguros/Planos de Saúde

Relatório apresentado à disciplina
Introdução à Ciência de Dados com R,
como requisito parcial para aprovação na
disciplina, sob a orientação do prof. Renan
Silva Santos.

RIO DE JANEIRO
2025

RESUMO

Planos de saúde possuem alta variabilidade em seus preços, baseada na análise de risco de cada indivíduo. Este estudo teve como objetivo desenvolver modelos de regressão para identificar e quantificar o impacto de fatores demográficos e de estilo de vida nos custos médicos. Utilizando um conjunto de dados público com 1.338 observações, a análise progrediu de um modelo linear geral para uma abordagem de **modelagem segmentada**, separando os indivíduos em grupos de fumantes e não fumantes. Os resultados revelaram que os fatores de custo operam sob "regras" fundamentalmente distintas para cada grupo. Para os **não fumantes**, os custos seguem um padrão previsível e moderado (R^2 ajustado $\approx 69\%$), influenciado principalmente pela idade (com efeito curvo), número de filhos e região. Para os **fumantes**, a dinâmica é mais complexa e de maior magnitude, resultando em um modelo de interação que explica **91,4%** da variabilidade dos custos. A principal conclusão é que o tabagismo atua como um amplificador de risco que, quando combinado com a **obesidade (IMC ≥ 30) e a idade**, eleva os custos de forma exponencial.

Palavras-chave: Custos médicos, Regressão linear múltipla, Idade, Índice de Massa Corporal, IMC, Tabagismo, Planos de saúde

LISTA DE ILUSTRAÇÕES

Figura 1 – Distribuição de custos médicos.....	10
Figura 2 – Distribuição logarítmica de custos médicos.....	11
Figura 3 – Custos médicos de fumantes e não fumantes.....	12
Figura 4 – Custos médicos por idade, diferenciados por status de tabagismo	12
Figura 5 – Custos médicos por IMC, diferenciados por status de tabagismo	13
Figura 6 – Relação entre Idade, IMC e Custos para Fumantes.....	14
Figura 7 – Relação entre Custo e Número de Filhos (Não Fumantes).....	16
Figura 8 – Comparação de Custos entre as Regiões Norte e Sul	16

LISTA DE ABREVIATURAS E SIGLAS

IMC Índice de Massa Corporal

SUMÁRIO

1 INTRODUÇÃO	7
1.1 Tema	7
1.2 Problematização e justificativa	7
1.3 Hipóteses	7
1.4 Objetivos	8
1.4.1 Objetivo geral	8
1.1.1 Objetivos específicos	8
2 REFERENCIAL TEÓRICO	9
3 METODOLOGIA	10
4 RESULTADOS E DISCUSSÃO	15
4.1 Modelo Geral Inicial	15
4.2 Análise do Subgrupo de Não Fumantes	15
4.3 Análise Aprofundada do Subgrupo de Fumantes	17
5 CONSIDERAÇÕES FINAIS	18
REFERÊNCIAS	19
APÊNDICE A - Resumos dos Modelos de Regressão Geral	20
APÊNDICE B - Resumos dos Modelos de Regressão para não fumantes	21
APÊNDICE C - Resumos dos Modelos de Regressão para fumantes	22
APÊNDICE D - Matriz de correlação para Não fumantes	25

1 INTRODUÇÃO

1.1 Tema

Os gastos médicos são um elemento de grande relevância para diferentes grupos na sociedade. A população em geral precisa conhecê-los para planejar e arcar com os custos relacionados à sua saúde; as seguradoras necessitam ser capazes de prevê-los para elaborar planos financeiramente sustentáveis; e os profissionais de saúde precisam compreendê-los para identificar os fatores que influenciam o custo do tratamento de um paciente.

Esse tema pode ser analisado sob uma perspectiva financeira, identificando os fatores populacionais que contribuem para o aumento ou redução dos custos médicos. Outra abordagem possível é a análise preventiva, que busca compreender os comportamentos associados ao desenvolvimento de condições de saúde responsáveis por custos mais elevados — seja por exigirem tratamentos mais caros, seja pela necessidade de atendimentos recorrentes.

1.2 Problemática e justificativa

O conhecimento dos fatores — sejam eles evitáveis ou não — que influenciam os custos da população com o setor de saúde é de extrema importância. No entanto, essas informações encontram-se dispersas entre clínicas, hospitais, grupos privados e operadoras de planos de saúde.

Compreender esses elementos permite ao indivíduo adotar medidas preventivas ou se preparar financeiramente para arcar com tais despesas, ao mesmo tempo em que possibilita às seguradoras alinhar seus planos de negócio de forma mais condizente com a realidade. Nesse sentido, um estudo baseado em uma ampla compilação de dados pode revelar informações valiosas tanto para o consumidor de um plano de saúde quanto para o fornecedor.

1.3 Hipóteses

Este estudo partiu da hipótese de que seria possível desenvolver um modelo preditivo capaz de explicar ao menos 70% da variabilidade dos custos médicos observados. Além disso, assumiu-se que existiriam relações estatisticamente

significativas entre os custos e três fatores principais: idade, índice de massa corporal (IMC) e hábito de tabagismo.

1.4 Objetivos

1.4.1 Objetivo geral.

Este estudo tem como objetivo desenvolver e avaliar um modelo de regressão linear múltipla para identificar e quantificar o impacto de fatores demográficos e de estilo de vida no potencial aumento nos custos médicos e como os mesmos podem influenciar valores praticados por seguradoras de planos de saúde.

1.1.1 Objetivos específicos

O estudo busca: realizar uma análise exploratória do conjunto de dados para caracterizar a população estudada; Verificar a existência de relações estatisticamente significativas entre os custos médicos e variáveis como idade, índice de massa corporal (IMC) e tabagismo; Estimar o poder explicativo do modelo proposto, verificando em que medida as variáveis selecionadas contribuem para explicar a variabilidade dos custos médicos; Identificar qual dos fatores analisados exerce maior impacto sobre os custos.

2 REFERENCIAL TEÓRICO

A análise desenvolvida neste estudo foi fundamentada em materiais de natureza técnica e didática. Para a implementação do código, recorreu-se à documentação oficial da linguagem R, que constitui a principal fonte de referência para o uso de suas funções estatísticas e gráficas. Em especial, a documentação do pacote ggplot2 foi utilizada como base para a construção de visualizações e análise exploratória dos dados, enquanto as funções estatísticas nativas do R serviram de suporte para a modelagem de regressão linear múltipla.

O conjunto de dados empregado é público e amplamente utilizado para fins educacionais em ciência de dados e estatística aplicada. Esse dataset contém informações de 1.338 indivíduos, incluindo variáveis demográficas e de estilo de vida, como idade, índice de massa corporal (IMC) e hábito de tabagismo, além dos respectivos custos médicos. Por sua estrutura organizada e relevância prática, essa base de dados é comumente utilizada em exercícios acadêmicos para ilustrar técnicas de modelagem estatística.

Além disso, os conceitos estatísticos aplicados foram embasados no conteúdo ministrado durante a disciplina de R, conduzida pelo professor Renan Silva Santos. As aulas forneceram tanto a fundamentação teórica quanto a orientação prática necessária para a execução da análise, permitindo o alinhamento entre teoria e prática no desenvolvimento do modelo.


3 METODOLOGIA

Como base de dados para a análise foi selecionado o Medical Cost Personal Dataset, disponível na plataforma Kaggle. Esse conjunto contém informações de 1.338 indivíduos norte-americanos, incluindo sexo, idade, número de filhos, índice de massa corporal (IMC), hábito de tabagismo, região dos Estados Unidos e custos médicos totais. O dataset foi escolhido por ser confiável e amplamente utilizado em estudos de regressão linear. Além disso, os dados já se encontram limpos, o que permite concentrar a análise na exploração das relações entre variáveis. O único ajuste realizado consistiu na transformação das variáveis categóricas (sexo, tabagismo e região) em fatores (factor), de modo a facilitar sua interpretação pela linguagem R.


Após essa preparação inicial, foi verificada a distribuição dos custos médicos com o objetivo de identificar possíveis tendências que pudessem influenciar os resultados.

Os gráficos a seguir apresentam a distribuição dos custos:

Figura 1 – Distribuição de custos médicos




Fonte: Saída do software R (2025).

Figura 2 – Distribuição logarítmica de custos médicos

Fonte: Saída do software R (2025).


A Figura 1 mostra uma forte concentração de custos médicos abaixo de 20.000 dólares, evidenciando a assimetria dos dados e a possibilidade de que valores extremos elevem de forma desproporcional a média. Para atenuar esse efeito, aplicou-se a transformação logarítmica, resultando na Figura 2. Nela, observa-se uma distribuição mais centralizada, o que reduz vieses e favorece análises mais robustas.

Em seguida, foi conduzida uma análise exploratória para investigar se os fatores definidos nas hipóteses — idade, tabagismo e IMC — influenciam os custos médicos. Para isso, foram construídos três gráficos utilizando o pacote ggplot2.

Figura 3 – Custos médicos de fumantes e não fumantes

Fonte: Saída do software R (2025).


A Figura 3 apresenta um boxplot que evidencia diferenças significativas entre os dois grupos. Em média, mesmo os maiores custos de não fumantes não alcançam os menores custos médios dos fumantes. Observam-se ainda alguns valores atípicos entre não fumantes, possivelmente relacionados a idade ou IMC elevados.

Figura 4 – Custos médicos por idade, diferenciados por status de tabagismo

Fonte: Saída do software R (2025).

A Figura 4, um gráfico de dispersão, ajuda a explicar parte dos valores atípicos identificados no boxplot. Nota-se uma tendência clara de aumento dos custos com o avanço da idade. A diferenciação por cor revela que a maioria dos não fumantes concentra-se em custos mais baixos, embora alguns se aproximem das faixas típicas de fumantes. Esses resultados reforçam que idade e tabagismo, em conjunto, exercem influência significativa e crescente sobre os custos médicos.

Figura 5 – Custos médicos por IMC, diferenciados por status de tabagismo



Fonte: Saída do software R (2025).


A Figura 5 indica que a relação entre IMC e custos médicos é menos expressiva quando comparada às variáveis anteriores. Observa-se grande concentração de indivíduos com custos abaixo de 20.000 dólares, sem tendência clara de crescimento. No entanto, ao separar os grupos por tabagismo, percebe-se entre fumantes uma tendência linear de aumento dos custos conforme cresce o IMC, sugerindo um possível efeito combinado entre essas variáveis.

A estratégia de modelagem foi dividida em três etapas principais. Primeiro, foi construído um **modelo geral inicial** para validar a influência dos preditores primários (idade, IMC, tabagismo) nos custos médicos em escala logarítmica.

Em seguida, reconhecendo o tabagismo como o principal fator de diferenciação, a análise foi **segmentada em dois subgrupos**: não fumantes e fumantes. Para o grupo de **não fumantes**, foi desenvolvido um modelo específico, buscando os preditores mais relevantes para essa população. Para o grupo de **fumantes**, cuja dinâmica de custos se mostrou mais complexa, foi realizada uma análise visual aprofundada (Figura 6) para entender a interação entre idade e IMC.

A análise da Figura 6 indicou uma mudança estrutural nos custos em torno do limiar de obesidade (IMC = 30). Com base nisso, a etapa final consistiu na construção de um **modelo unificado para fumantes**, utilizando uma variável indicadora para obesidade (*is_obese*) e seus termos de interação com *idade* e *imc*.

Figura 6 – Relação entre Idade, IMC e Custos para Fumantes



Fonte: Saída do software R (2025).

4 RESULTADOS E DISCUSSÃO


4.1 Modelo Geral Inicial

O primeiro modelo, aplicado a todos os 1.338 indivíduos, demonstrou um bom poder explicativo (R^2 ajustado de 74,4%) e confirmou que *idade*, *IMC* e *tabagismo* são preditores estatisticamente significativos. O tabagismo se destacou como o fator de maior impacto: mantendo os outros fatores constantes, ser fumante está associado a um aumento médio nos custos de aproximadamente **370%** ($e^{(1.545)} - 1$). Cada ano de idade e ponto de IMC representam aumentos mais modestos, de 3,5% e 1,1%, respectivamente. A análise diagnóstica deste modelo (disponível no Apêndice A) indicou, no entanto, a presença de heterocedasticidade, justificando a análise segmentada.


4.2 Análise do Subgrupo de Não Fumantes

A análise para o subgrupo de não fumantes buscou identificar os principais preditores de custo na ausência do fator tabagismo. A seleção de variáveis para o modelo foi guiada por uma análise de correlação (**Apêndice D**), que apontou *idade* e *número de filhos* como os fatores mais relevantes.

Adicionalmente, a análise gráfica exploratória (Figuras 7 e 8) confirmou visualmente essas relações e a importância da divisão regional.

Figura 7 – Relação entre Custo e Número de Filhos (Não Fumantes)

Fonte: Saída do software R (2025).

Figura 8 – Comparação de Custos entre as Regiões Norte e Sul

Fonte: Saída do software R (2025).

O modelo final, para este grupo, alcançou um **R² ajustado de 68,6%**. A análise confirmou que os custos para este grupo são majoritariamente influenciados pela *idade* (com um efeito curvo que desacelera com o tempo), pelo *número de filhos* e pela *região*. Além disso, o *IMC* não mostrou ser um preditor relevante, indicando que

seu impacto no custo está fortemente condicionado ao hábito de fumar. Os gráficos de diagnóstico (Apêndice B) validaram a robustez deste modelo, que apresentou boa homocedasticidade.

4.3 Análise Aprofundada do Subgrupo de Fumantes

A análise visual (Figura 6) revelou que a combinação de idade avançada e obesidade ($\text{IMC} \geq 30$) leva a custos exponencialmente mais altos. Essa observação foi a chave para a construção de um modelo unificado para fumantes, que alcançou um poder explicativo excepcional, com **R^2 ajustado de 91,4%**.

O sucesso deste modelo final valida a hipótese central da análise: os efeitos da idade e do IMC sobre os custos são fundamentalmente diferentes para fumantes obesos e não obesos. A abordagem de interação se mostrou a mais precisa e estatisticamente sólida para descrever a dinâmica de custos dentro deste complexo grupo, com excelente homocedasticidade confirmada pelos gráficos de diagnóstico (Apêndice C).

5 CONSIDERAÇÕES FINAIS

Este estudo conseguiu identificar com sucesso os principais preditores de custos médicos. A análise segmentada revelou que os fatores de custo operam sob "regras" distintas para fumantes e não fumantes. Enquanto para os não fumantes os custos seguem um padrão previsível e moderado influenciado pela idade, para os fumantes os custos são exponencialmente maiores e impulsionados por uma complexa interação entre idade e, crucialmente, o status de obesidade. A abordagem de modelagem dividida foi essencial para capturar essas dinâmicas distintas com alta precisão e validade estatística.

Enquanto para os não fumantes os custos seguem um padrão previsível e moderado, para os fumantes eles são impulsionados por uma complexa interação entre idade e, crucialmente, o status de obesidade. A abordagem de modelagem segmentada foi essencial para capturar essas dinâmicas com alta precisão, resultando em modelos robustos e com alto poder preditivo.

Apesar da significância dos resultados, é importante destacar que os dados analisados referem-se exclusivamente a uma população dos Estados Unidos, não refletindo necessariamente outras realidades. Além disso, a ausência de variáveis clínicas adicionais pode ter limitado o modelo, especialmente em relação aos custos muito elevados, que não foram previstos com precisão.

REFERÊNCIAS

KAGGLE. **Medical Cost Personal Dataset**. Kaggle, 2017.

Disponível em: <https://www.kaggle.com/datasets/mirichoi0218/insurance>. Acesso em: 16 set. 2025.

R CORE TEAM. **R: A Language and Environment for Statistical Computing**.

Vienna: R Foundation for Statistical Computing, 2023.

Disponível em: <https://www.r-project.org>. Acesso em: 16 set. 2025.

SANTOS, Renan. **Material didático da disciplina de R**. [S.l.: s.n.], 2025. Notas de aula.

WICKHAM, H. **ggplot2: Elegant Graphics for Data Analysis**. 2. ed. Nova Iorque: Springer, 2016.

Disponível em: <https://ggplot2.tidyverse.org/>. Acesso em: 16 set. 2025.

APÊNDICE A - Resumos dos Modelos de Regressão Geral

Tabela A.1 – Resumo do modelo de regressão geral





Figura A.1 – Gráficos de diagnóstico do novo modelo geral



Fonte: Saída do software R (2025).

APÊNDICE B - Resumos dos Modelos de Regressão para não fumantes

Tabela B.1 – Resumo do modelo de regressão para não fumantes





Figura B.1 – Gráficos de diagnóstico do novo modelo para não fumantes



Fonte: Saída do software R (2025).

APÊNDICE C - Resumos dos Modelos de Regressão para fumantes

Tabela C.1 – Resumo do modelo de regressão para fumantes não obesos (IMC < 30)





Figura C.1 – Gráficos de diagnóstico do modelo para fumantes não obesos (IMC < 30)



Fonte: Saída do software R (2025).

Tabela C.2 – Resumo do modelo de regressão para fumantes obesos (IMC >= 30)

```

Call:
lm(formula = log(charges) ~ bmi + age, data = fumantes_obesos)


Residuals:
    Min       1Q   Median       3Q      Max
-0.56668 -0.02850 -0.01592  0.00222  0.44756

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  9.8977727   0.0667356  148.313   < 2e-16 ***
bmi           0.0130746   0.0017859    7.321 1.67e-11 ***
age           0.0067140   0.0005235   12.826   < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.0899 on 142 degrees of freedom
Multiple R-squared:  0.6091,    Adjusted R-squared:  0.6036
F-statistic: 110.6 on 2 and 142 DF,  p-value: < 2.2e-16

```

Figura C.2 – Gráficos de diagnóstico do modelo para fumantes obesos (IMC ≥ 30)



Fonte: Saída do software R (2025).

Tabela C.3 – Resumo do novo modelo de regressão para fumantes


```
Call:
lm(formula = log(charges) ~ (age + bmi) * is_obese, data = fumantes)

Residuals:
    Min       1Q   Median       3Q      Max
-0.56668 -0.03648 -0.01938 -0.00038  0.67846

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  8.9662193  0.0841898 106.500 < 2e-16 ***
age           0.0120106  0.0007459  16.102 < 2e-16 ***
bmi           0.0206673  0.0031894   6.480 4.38e-10 ***
is_obese      0.9315534  0.1191504   7.818 1.23e-13 ***
age:is_obese -0.0052966  0.0009969  -5.313 2.27e-07 ***
bmi:is_obese -0.0075927  0.0039068  -1.943  0.053 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1136 on 268 degrees of freedom
Multiple R-squared:  0.9157,    Adjusted R-squared:  0.9141
F-statistic: 582 on 5 and 268 DF,  p-value: < 2.2e-16
```


Figura C.3 – Gráficos de diagnóstico do novo modelo para fumantes



Fonte: Saída do software R (2025).

APÊNDICE D - Matriz de correlação para Não fumantes

Figura D.1 – Matriz de correlação



Fonte: Saída do software R (2025).